

LAPORAN PROJECT DATA MINING
SEMESTER GENAP 2024/2025

IDENTITAS PROYEK	
Judul	Deteksi Rasisme pada Media Sosial Berbahasa Indonesia Menggunakan Machine Learning
Topik	Analisis Sentimen
Identitas Penyusun	1. Muhammad Dafa Alvian Ramadhani (23031554017) 2. Faishal Bayu Pratama (23031554092) 3. Azriel Kevin Alfarizqi (23031554190) 4. Muhammad Alif Mahbubi (23031554031)
Kelas	Sains Data 2023D

1. PENDAHULUAN

Pendahuluan penelitian tidak lebih dari 1000 kata yang terdiri dari:

- A. Latar belakang dan rumusan permasalahan yang akan diteliti
- B. Pendekatan pemecahan masalah

1.1.Latar Belakang (min. 250 kata)

Dalam era digital saat ini, media sosial telah menjadi sebuah platform utama bagi masyarakat untuk berinteraksi, berbagi opini, dan mengekspresikan diri. Namun, kebebasan dalam berpendapat yang ditawarkan oleh media sosial juga membuka peluang besar bagi penyebaran ujaran kebencian, termasuk rasisme. Hal ini dapat dibuktikan dengan adanya studi yang menunjukkan bahwa ujaran kebencian terhadap kelompok etnis tertentu, seperti etnis Tionghoa di Indonesia, masih marak terjadi di dunia maya. Analisis terhadap ujaran kebencian berbasis ras di media sosial menunjukkan bahwa ujaran ini tidak hanya mengandung ekspresi kebencian, tetapi juga berpotensi melahirkan diskriminasi nyata di masyarakat dan melanggar hak asasi manusia (Floranti, 2022).

Rasisme dalam komentar media sosial berbahasa Indonesia dapat berdampak negatif terhadap kohesi sosial, meningkatkan konflik, serta memperparah diskriminasi berbasis ras dan etnisitas. Permasalahan rasisme di Indonesia tidak dapat dipandang sebelah mata. Meskipun Indonesia dikenal dengan keberagaman etnis dan budayanya, insiden diskriminasi berbasis ras dan etnisitas masih sering terjadi, termasuk dalam ranah daring (Floranti, 2022)Media sosial mempercepat penyebaran ujaran bernuansa rasis, di mana individu atau kelompok tertentu menjadi sasaran stereotip negatif, stigma, dan penghinaan berbasis etnis yang berpotensi memperburuk ketegangan sosial.

Deteksi rasisme secara manual menjadi tidak efisien mengingat volume komentar yang sangat besar dan pertumbuhannya yang cepat. Oleh karena itu, pendekatan berbasis machine learning diperlukan untuk mengidentifikasi komentar bernuansa rasis secara otomatis dan efisien. Pendekatan berbasis pembelajaran mesin telah menunjukkan efektivitas dalam meningkatkan akurasi dan efisiensi klasifikasi teks, termasuk untuk mendeteksi ujaran kebencian di berbagai bahasa (Sartini & Adrian, 2023).

Walaupun studi deteksi ujaran kebencian cukup berkembang untuk bahasa Inggris, penelitian dalam konteks bahasa Indonesia masih relatif terbatas. Tantangan tambahan muncul karena karakteristik khas dalam penggunaan bahasa Indonesia di media sosial, seperti penggunaan slang, kode campur, serta konteks budaya tertentu yang mempengaruhi makna ujaran(Sartini & Adrian, 2023). Oleh karena itu, diperlukan pengembangan model deteksi rasisme yang dirancang khusus untuk memahami karakteristik linguistik komentar berbahasa Indonesia, guna menciptakan ruang digital yang lebih sehat dan inklusif.

1.2.Rumusan Masalah dan Tujuan

Rumusan Masalah :

1. Bagaimana cara mendeteksi komentar rasis di media sosial berbahasa indonesia secara otomatis dan efisien?
2. Bagaimana menerapkan machine learning untuk mengklasifikasi komentar rasis dan non rasis secara akurat?
3. Bagaimana menangani masalah ketidakseimbangan data dalam klasifikasi komentar rasis?

Tujuan :

1. Mengevaluasi kinerja beberapa algoritma klasifikasi (SVM, Random Forest, dan Naive Bayes) dalam mendeteksi komentar rasisme.
2. Melakukan preprocessing dan normalisasi teks untuk menangani keragaman bahasa dalam komentar pada media sosial.
3. Meningkatkan performa model dalam mengenali kelas minoritas melalui teknik penyeimbangan data seperti SMOTE.
4. Membandingkan efektivitas metode representasi teks (TF-IDF dan BOW) dalam mendukung klasifikasi komentar rasis.

12. Metodologi

Metodologi atau cara untuk mencapai tujuan yang telah ditetapkan ditulis tidak melebihi 1000 kata. Bagian ini berisi metode pre-processing dan/atau metode post processing yang dilengkapi dengan diagram alir penelitian yang menggambarkan apa yang sudah dilaksanakan dan yang akan dikerjakan selama waktu yang diusulkan. Format diagram alir dapat berupa file JPG/PNG. Metode penelitian harus dibuat secara utuh dengan penahapan yang jelas.


2.1.Eksplorasi Dataset

Pemahaman dataset yang dimiliki

Data yang digunakan diambil dari tiga repository GitHub terpisah, masing-masing menyajikan korpus teks dengan fokus berbeda (hate speech, abusive language, dan SARA). Walaupun struktur dan tujuan anotasi tiap dataset tidak sepenuhnya seragam, semuanya relevan untuk membangun model deteksi konten berbau rasisme.

Eksplorasi awal terhadap keempat dataset menunjukkan variasi ukuran dan fokus konten yang relevan dengan analisis ujaran kebencian dan rasisme. Dataset pertama terdiri dari 686 baris dan 3 kolom, 3 kolom tersebut berisi no (nomor entri), tweets (teks tweet), dan label (kategori rasis/non rasis). Dataset kedua lebih besar dengan 13.169 baris dan 13 kolom, mencakup Tweet (teks), HS (0/1, hate speech), Abusive (0/1, pelecehan), HS_Individual, HS_Group, HS_Religion, HS_Race, HS_Disability, HS_SexualOrientation, HS_Gender, HS_Other (subkategori HS), HS_Weak, HS_Moderate, HS_Strong (tingkat intensitas). Dataset ketiga berisi 778 baris dan 6 kolom yang mencakup original_text, source, pornografi (0/1), sara (0/1), radikalisme (0/1), pencemaran_nama_baik (0/1). Dan dataset terakhir memiliki 6996 baris dan 6 kolom terdiri dari original_text, source, pornografi (0/1), sara (0/1), radikalisme (0/1), pencemaran_nama_baik (0/1). Dengan keberagaman struktur dan fokus ini, keempat dataset memberikan kerangka yang kaya untuk memahami berbagai bentuk, konteks, dan tingkat rasisme dalam teks.

2.2.Tahapan Penelitian



1. Data Collecting

Pada tahap data collecting, dataset diperoleh dari sumber GitHub, Dataset yang digunakan terdiri dari tiga sumber yang berbeda yang dimana masing masing berisi komentar yang ada pada media sosial yang ditulis dalam bahasa Indonesia

2. Data Exploration

Exploratory Data Analysis (EDA) adalah proses memahami data melalui manipulasi dan visualisasi data. Ini merupakan langkah penting dalam setiap proyek sains data (Peng et al., 2021). EDA digunakan untuk visualisasi dan ekstraksi informasi yang lebih mendalam namun kurang terlihat secara langsung dari data (Camizuli & Carranza, 2018). Pada proyek ini EDA yang dilakukan meliputi cek data infonya, lalu melihat adanya missing value, melakukan cek duplikasi data, melihat distribusi label dengan bar chart, Selanjutnya melihat total kata terbanyak dan yang terakhir Word of Cloud.

3. Data Selection

Untuk memfokuskan analisis pada deteksi konten rasisme, setiap dataset disederhanakan hanya pada kolom teks asli dan kolom label yang relevan dengan unsur rasisme atau SARA. Dengan demikian, pipeline preprocessing dan modeling dapat lebih efisien dan terarah. Di dataset 1, teks tweet telah diberi label biner rasis vs non-rasis, sementara di dataset 2. kita hanya mengambil indikator hate speech berbasis ras. dataset 3 dan dataset 4 memiliki skema multi-label SARA, namun kita hanya memilih label sara untuk konsistensi deteksi konten SARA.

Secara ringkas, kolom yang digunakan adalah:

- Rasis 1:
 1. Teks: tweets
 2. Label: label (non-rasis, rasis)
- Rasis 2:
 1. Teks: Tweet
 2. Label: HS_Race (0 = non-rasial, 1 = hate speech berbasis ras)
- Rasis 3:
 1. Teks: original_text
 2. Label: sara (0 = bukan SARA, 1 = SARA)
- Rasis 4:
 1. Teks: original_text
 2. Label: sara (0 = bukan SARA, 1 = SARA)

Dengan pemilihan ini, setiap dataset kini hanya memuat dua kolom teks dan label rasisme sehingga langkah selanjutnya dapat dilakukan secara konsisten di seluruh kumpulan data.

4. Data Integration

Pada tahap Data Integration, keempat dataset yang telah disederhanakan (hanya memuat kolom teks dan label rasisme/SARA) digabung menjadi satu file. Prosesnya meliputi beberapa langkah berikut:

Standarisasi Kolom

Semua kolom teks diberi nama text, sementara kolom label diseragamkan menjadi label, sehingga struktur setiap sumber data menjadi konsisten.

Pemilahan dan Pemuatan

Dari dataset 1 diambil kolom tweets sebagai text dan label bawaan;

dari dataset 2 diambil Tweet sebagai text dan HS_Race sebagai label;

dari dataset 3 dan dataset 4 masing-masing diambil original_text sebagai text dan sara sebagai label.

Penggabungan Data

Keempat data frame tersebut disatukan secara vertikal, menghasilkan satu kumpulan data besar tanpa indeks terpisah.

Hasil gabungan disimpan dalam berkas CSV tunggal (RASIS.csv) yang berisi dua kolom utama (text, label) dan 21.628 baris yang siap digunakan untuk tahap preprocessing dan tahap-tahap selanjutnya.

5. Pre-Processing

Dalam progress kami, berikut adalah beberapa tahapan preprocessing yang telah kami terapkan pada dataset:

- Menghapus semua mention pengguna di media sosial, yaitu kata-kata yang diawali dengan simbol @.
- Menghapus semua hashtag, yaitu kata-kata yang diawali dengan simbol #
- Menghapus retweet (RT)
- Menghapus angka
- Menghapus semua tautan yang berbentuk URL.
- Menghapus newline atau carriage return (\n atau \r) dan menggantinya dengan spasi agar teks menjadi satu baris.
- Menghapus karakter non-ASCII (seperti karakter rusak karena kesalahan encoding)
- Menghapus tanda baca, seperti titik, koma, tanda tanya, dll agar teks lebih bersih.
- Menghapus spasi yang tidak diperlukan di awal atau akhir teks.
- Mengubah seluruh huruf dalam teks menjadi huruf kecil.
- Melakukan translasi beberapa bahasa inggris ke bahasa indonesia.
- Mengubah kata singkatan ke kata asli menggunakan kamus.
- Menghapus kata hubung
- Menghapus kata-kata yang dianggap tidak memiliki kontribusi penting.
- Menghapus kata-kata yang sering muncul dalam teks tetapi tidak relevan.
- Mengubah emoji menjadi teks sesuai makna emoji
- Mengubah emoticon menjadi teks sesuai makna emoticon
- Normalisasi teks dengan mengganti kata-kata tidak baku menjadi kata baku.

Adapun berikut adalah sampel data hasil pre processing:

Teks Hasil Pre Processing:

1. terus nih bertanya tidak dibangun papua provinsi timur indonesia memiliki infrastruktur fasilitas pengolahan lanjutan memadai
2. play let the fun begin like click did kamu see it pictwittercomaefixr
3. papua negara kesatuan republik indonesia
4. akar konflik dibicarakan dicari titik temu selesai saya saya papua sambutan dengan nyanyian rohani menyejukkan saya tuhan yesus kristus dipapua semoga buruk dari manapun tidak tym papua
5. papua kulit hitam kulit putih rambut keriting rambut lurus mata sipit mata menyala indonesia to edo kondologit pictwittercomormkscbvw
6. kasiankah ujungnya mereka jadi kurir politik atas nama bela ndugabukan papua
7. ssb united sentani juara i sepak bola pangdamcup
8. vk berhasil menyerahkan papua majika cinanya imigran cina mengalir deras penjarahan sejati orang cina lakukan genosida benaran cina oap oap menyesal mengenal vk
9. nih diskriminasi papua terkait penegakan hukum tunggu lapor propam
10. video bokep papua
11. papua indonesia lo
12. see kamu next time again pulau raja ampat terima kasih keindahanmu sentani airport jayapura papua pictwittercomfcsiefasx
13. dibayar bagus segeralah bayar meluas masuk proses mohon perhatian disord provinsi papua
14. enggak sombong jaminannya rakyat indonesia membelamu kalau menjual papua untuk popularitas rakyat papua menderita mending pulang mempertanggungjawabkan perbuatanmu
15. haha bangsat gue ikutan papua kamu

6. Feature Engineering

Setelah dataset dibersihkan dan disiapkan di tahap pre processing, maka tahap selanjutnya adalah mengubah text yang ada ke dalam fitur numerik agar nantinya bisa terbaca oleh komputer. Adapun teknik feature engineering yang sudah diterapkan adalah:

1. TF IDF

TF-IDF adalah statistik numerik yang menunjukkan relevansi kata kunci terhadap dokumen tertentu, atau dapat dikatakan bahwa metode ini menyediakan kata kunci yang dapat digunakan untuk mengidentifikasi atau mengkategorikan dokumen tertentu (Kaiser & Ali, 2018). *Term Frequency-Inverse Document Frequency* adalah metode yang paling umum digunakan dalam *Natural Language Processing* (NLP) untuk mengubah dokumen teks menjadi representasi matriks vektor (Singh & Shashi, 2019). Informasi kategori teks dimasukkan ke dalam rumus pembobotan TF-IDF dan kemudian dikombinasikan dengan *word vector* dari Word2vec. Akhirnya, teks diklasifikasikan dengan menggabungkan model tersebut dengan model ruang vektor tradisional (Liu et al., 2018). Algoritma TF-IDF digunakan untuk meningkatkan bobot istilah yang sering muncul dalam suatu kelas, dan menggunakan TF-IDF yang telah ditingkatkan tersebut untuk melatih pengklasifikasi dalam mengklasifikasi teks, sehingga meningkatkan hasil klasifikasi teks (Liu et al., 2018).

2. BoW (Bag of Words)

BoW digunakan untuk merepresentasikan jumlah kemunculan suatu kata dalam sebuah dokumen (Sajeetha Thavareesan & Sinnathamby Mahesan, 2019). Model tradisional untuk klasifikasi teks berbasis topik didasarkan pada representasi *bag-of-words* (BoW), yang mengasosiasikan sebuah teks dengan vektor yang menunjukkan jumlah kemunculan setiap kata yang dipilih dalam korpus pelatihan (HaCohen-Kerner et al., 2020).

7. Modeling

Langkah Selanjutnya, setelah data dibagi menjadi train dan test serta melalui tahap feature engineering, maka masuk ke tahap modelling. Dimana disini kami memakai tiga algoritma klasifikasi yang meliputi:

1. SVM

Support Vector Machine (SVM) adalah algoritma pembelajaran terawasi (supervised learning) yang digunakan untuk klasifikasi dan regresi (Muawanah et al., 2023). SVM bekerja dengan mengurangi beban dalam membandingkan pola harga saat ini dengan pola historis. Dengan menggunakan SVM, kita dapat mengimplementasikan klasifikasi data dan memetakan setiap data sebagai titik dalam bidang berdimensi- n , di mana n merupakan jumlah atribut unik dalam dataset. Proses klasifikasi dilakukan dengan mencari hyperplane yang secara jelas memisahkan dua kelas (Kurani et al., 2023). SVM sangat efektif dalam menangani data berdimensi tinggi dan tetap efisien meskipun jumlah fitur lebih besar daripada jumlah sampel

2. Random Forest

Random forest adalah kumpulan dari pohon klasifikasi dan regresi, yang merupakan model sederhana dengan membagi secara biner variabel prediktor untuk menentukan prediksi hasil (Speiser et al., 2019). Dalam pendekatan random forest, banyak pohon klasifikasi dan regresi dibangun menggunakan dataset pelatihan yang dipilih secara acak dan subset acak dari variabel prediktor untuk memodelkan hasil. Hasil dari setiap pohon kemudian digabungkan untuk memberikan prediksi pada setiap observasi. Oleh karena itu, random forest seringkali memberikan akurasi yang lebih tinggi dibandingkan dengan model decision tree tunggal, sambil tetap mempertahankan beberapa keunggulan dari model pohon seperti kemampuan untuk menginterpretasikan hubungan antara variabel prediktor dan hasil (Speiser et al., 2019). Selain itu, random forest juga memiliki ketahanan terhadap overfitting karena pendekatannya yang menggabungkan banyak pohon keputusan dengan data dan fitur yang bervariasi.

3. Naive Bayes

Klasifikasi Naïve Bayes merupakan salah satu jenis utama dari pendekatan probabilistik dalam teknik machine learning (Surya Prabha PM & Subbulakshmi B, 2019). Salah satu keunggulan dari klasifikasi Naïve Bayes adalah hanya memerlukan estimasi parameter yang diperlukan (rata-rata dan varians dari variabel) berdasarkan sejumlah kecil data pelatihan. Karena adanya asumsi bahwa variabel-variabel bersifat independen, hanya diperlukan estimasi untuk masing-masing variabel secara terpisah tanpa perlu menghitung matriks kovarians secara keseluruhan (Chen et al., 2021). Metode ini sangat cocok digunakan dalam pemrosesan bahasa alami dan teks

skala besar karena efisiensinya yang tinggi dalam proses komputasi dan kemampuannya menangani data berdimensi tinggi.

3. Hasil dan Analisis

3.1 Exploratory Data Analysis

Pada tahap ini EDA yang pertama dilakukan adalah mengecek info dari data yang dipakai setelah tahap penggabungan data dengan menggunakan `data.info()`.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21628 entries, 0 to 21627
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype  
---  -
0    tweets    21628 non-null  object 
1    label     21628 non-null  int64   
dtypes: int64(1), object(1)
memory usage: 338.1+ KB
```

Pada data ini terlihat bahwa total baris dari hasil penggabungan data atau data integration adalah 21.628 baris dengan total 2 kolom yaitu kolom tweets dan kolom label dengan tipe data untuk tweets berupa object dan label berupa int64.

Tahap selanjutnya adalah pengecekan missing value dengan menggunakan `data.isnull().sum()`, ini dilakukan agar data yang akan di proses nantinya tidak ada kekurangan pada data.


```
0
tweets  0
label   0
dtype: int64
```

Dapat dilihat dari data ini tidak terdapat adanya missing value, maka selanjutnya dilakukan proses pengecekan data yang duplikat menggunakan `data.duplicated().sum()`

```
[ ] data.duplicated().sum()
np.int64(897)
```


Dapat dilihat dari output tersebut, bahwa data tersebut memiliki data yang duplikat sebanyak 897 data, yang dimana selanjutnya kita akan handle data yang duplikat ini dengan drop semua data yang duplikat, ini bertujuan untuk memastikan kualitas dan keakuratan data dalam analisis selanjutnya dan menghindari bias terutama untuk proses machine learning, dan juga dapat bisa meningkatkan kinerja model machine learning. Setelah dilakukan penghapusan data yang duplikat kini data menjadi 20.731 baris.

Pada tahap selanjutnya dilakukan visualisasi distribusi label dengan menggunakan bar chart, ini bertujuan untuk melihat jumlah data yang memiliki label 0 atau 1, ini penting untuk untuk mengidentifikasi apakah terdapat ketidakseimbangan data atau imbalance dalam distribusi label. Imbalanced data classification adalah permasalahan di mana proporsi ukuran kelas dalam suatu dataset berbeda secara signifikan. Dalam kasus ini, satu kelas hanya diwakili oleh sejumlah kecil sampel (disebut kelas minoritas), sementara sisanya termasuk dalam kelas lain yang jumlahnya jauh lebih banyak (disebut kelas mayoritas) (Kaur et al., 2019). Berikut visualisasi distribusi label:




Dapat dilihat pada visualisasi distribusi label tersebut label 0 memiliki total 18839 data dan untuk label 1 memiliki total 1892 data, ini mengindikasikan bahwa kelas mayoritas (label 0) jauh lebih dominan dibandingkan kelas minoritas (label 1), ini disebut class imbalance. Imbalance ini berpotensi menyebabkan model prediktif menjadi bias terhadap kelas mayoritas yang berarti model akan cenderung memprediksi sebagian besar data sebagai label 0. Akibatnya, performa model dalam mengenali label 1 menjadi sangat rendah. Ini nantinya diperlukan metode untuk menyeimbangkan data agar tidak bias.

Selanjutnya melihat total kata yang paling sering muncul, ini penting untuk mencegah kemungkinan terjadinya kata yang sering muncul adalah kata yang tidak jelas atau bahkan huruf yang tidak jelas.



Dilihat dari visualisasi tersebut kata yang paling sering muncul adalah kata 'â' dan juga kata yang seperti karakter error lainnya, yang dimana ini nantinya akan mempengaruhi proses pada machine learningnya, ini perlu ditangani pada proses preprocessing. Selanjutnya

melihat visualisasi word of cloudnya, word of cloud ini diambil dari kata yang paling sering muncul.




3.2 Hasil Eksperimen


Hasil Pre Processing

Setelah dilakukan beberapa tahapan preprocessing, berikut adalah rangkuman analisis data bersih:

Berdasarkan Grafik




Sebelum Pre Processing



Setelah Pre Processing

Berdasarkan Wordcloud



Sebelum Pre Processing



Setelah Pre Processing

Dari visualisasi di atas, dapat didapatkan insight, bahwa dataset yang belum dilakukan pembersihan, masih didominasi oleh kata kata umum seperti kata ganti, stopword atau kata hubung, ataupun bahkan simbol simbol yang tidak berkaitan dengan topik proyek. Namun, setelah dilakukan preprocessing, terlihat beberapa kata yang mulai terlihat dan sesuai dengan topik deteksi rasis. Meskipun kata seperti “pengguna”, “tertawa” juga merupakan salah satu kata yang bias - dalam arti tidak sesuai konteks, namun beberapa kata seperti “anjing”, “goblok”, “cina”, “kafir” ataupun kata kata rasis lainnya mulai terlihat. Hal ini menunjukkan bahwa tahap pre processing mempengaruhi dataset dan keakuratan model

Hasil Pemodelan

Dalam proyek ini, dilakukan perbandingan kinerja tiga algoritma klasifikasi untuk mendeteksi apakah gambar uang termasuk kategori asli atau palsu, yaitu: Random Forest, Support Vector Machine (SVM), dan Naive Bayes. Berikut adalah tabel Perbandingan Algoritma dengan eksperimen tanpa smote dan menggunakan smote:

Tanpa Smote

Vektorisasi	Random Forest	SVM	Naive Bayes
TF-IDF	Accuracy: 0.932	Accuracy: 0.925	Accuracy: 0.920
	F1: 0.926	F1: 0.918	F1: 0.895
	Recall: 0.932	Recall: 0.925	Recall: 0.920
BoW	Accuracy: 0.897	Accuracy: 0.722	Accuracy: 0.874
	F1: 0.873	F1: 0.770	F1: 0.889
	Recall: 0.897	Recall: 0.722	Recall: 0.874

Dengan Smote

Vektorisasi	Random Forest	SVM	Naive Bayes
TF-IDF	Accuracy: 0.920	Accuracy: 0.851	Accuracy: 0.820
	F1: 0.922	F1: 0.874	F1: 0.851
	Recall: 0.920	Recall: 0.851	Recall: 0.820
BoW	Accuracy: 0.846	Accuracy: 0.834	Accuracy: 0.844
	F1: 0.867	F1: 0.857	F1: 0.866
	Recall: 0.846	Recall: 0.834	Recall: 0.844

Analisis Kesimpulan

Berdasarkan tabel di atas, setelah dilakukan Eksperimen dalam dua skenario, yakni tanpa penggunaan SMOTE dan dengan SMOTE. Algoritma SMOTE (Synthetic Minority Over-sampling Technique) adalah algoritma yang dikembangkan untuk menangani data yang tidak seimbang. Pada dasarnya, algoritma SMOTE memperoleh sampel baru melalui interpolasi linier secara acak antara beberapa sampel minoritas dengan sampel-sampel tetangganya. Rasio ketidakseimbangan data ditingkatkan dengan menghasilkan sejumlah sampel minoritas buatan, sehingga efek klasifikasi pada dataset yang tidak seimbang dapat diperbaiki (Wang et al., 2021). Hasilnya, pada skenario tanpa SMOTE, kombinasi model Random Forest dengan TF-IDF menunjukkan performa paling unggul dengan akurasi, F1-score, dan recall yang tinggi yaitu sebesar 0.932. Model SVM dan Naive Bayes juga menunjukkan kinerja yang baik ketika dikombinasikan dengan TF-IDF, namun SVM menunjukkan performa yang cukup rendah saat digunakan bersama BoW, dengan akurasi hanya sebesar 0.722. Secara umum, TF-IDF memberikan hasil yang lebih baik dibandingkan BoW di hampir semua model.

Ketika SMOTE diterapkan untuk menangani ketidakseimbangan kelas, terjadi penurunan akurasi pada hampir seluruh model, terutama Random Forest dan Naive Bayes. Namun demikian, F1-score pada beberapa model justru mengalami peningkatan, yang menandakan bahwa penggunaan SMOTE membantu model dalam mengidentifikasi kelas minoritas dengan lebih baik. Sebagai contoh, kombinasi SVM dengan BoW dan SMOTE menghasilkan F1-score sebesar 0.857, yang lebih tinggi dibandingkan versi tanpa SMOTE. Meskipun begitu, penurunan akurasi yang terjadi harus dipertimbangkan apabila model ditujukan untuk situasi di mana kesalahan klasifikasi memiliki dampak signifikan.


Berdasarkan keseluruhan hasil, dapat disimpulkan bahwa TF-IDF merupakan metode vektorisasi yang paling konsisten dalam menghasilkan performa model yang baik. Model Random Forest dengan TF-IDF tanpa SMOTE merupakan kombinasi terbaik untuk mendeteksi komentar rasis, terutama ketika akurasi dan recall menjadi prioritas utama. Penggunaan SMOTE bisa dipertimbangkan apabila terdapat ketimpangan distribusi kelas yang cukup besar, namun harus diimbangi dengan evaluasi terhadap trade-off pada akurasi. Akhirnya, keberhasilan dalam mendeteksi komentar rasis sangat bergantung pada kualitas pre-processing yang dilakukan, karena fitur teks yang bersih dan relevan akan mempermudah model dalam mengenali pola ujaran kebencian dengan lebih efektif.

```

Accuracy: 0.9276585483482035
F1-Score: 0.9175444102562502
Recall: 0.9276585483482035
Classification Report:


```

	precision	recall	f1-score	support
0	0.94	0.98	0.96	3764
1	0.70	0.38	0.49	383
accuracy			0.93	4147
macro avg	0.82	0.68	0.73	4147
weighted avg	0.92	0.93	0.92	4147




Matriks Konvusi

Actual Class Distribution



Predicted Class Distribution



Distribusi Label

Dokumentasi dan Laporan Model Klasifikasi Random Forest

3.3 Kesimpulan dan Saran

Projek ini berhasil merancang dan mengimplementasikan sistem deteksi komentar rasis pada media sosial berbahasa Indonesia menggunakan pendekatan machine learning, khususnya dengan algoritma Support Vector Machine (SVM), Random Forest, dan Naive Bayes. Dari hasil eksperimen, kombinasi Random Forest dengan metode representasi teks TF-IDF tanpa menggunakan SMOTE menunjukkan performa terbaik, dengan akurasi mencapai 93,2%, F1-score sebesar 92,6%, dan recall sebesar 93,2%. Metode TF-IDF secara umum terbukti lebih unggul dibandingkan dengan Bag of Words dalam menghasilkan model yang konsisten dan akurat. Penggunaan teknik SMOTE juga memberikan kontribusi positif dalam meningkatkan sensitivitas model terhadap kelas minoritas, meskipun disertai dengan sedikit penurunan akurasi. Hasil ini menunjukkan bahwa penyeimbangan data dapat meningkatkan kemampuan model dalam mengenali komentar rasis, tetapi perlu dipertimbangkan kembali apabila akurasi menjadi prioritas utama. Selain itu, kualitas tahap preprocessing terbukti sangat krusial dalam proses klasifikasi, karena data teks yang bersih dan relevan memudahkan model dalam mengenali pola ujaran kebencian.

Sebagai saran, untuk penelitian selanjutnya, perlu dilakukan eksplorasi lebih dalam terhadap teknik teks processing yang lebih adaptif terhadap konteks lokal bahasa Indonesia, seperti penggunaan model leksikon khusus ujaran kebencian atau kamus slang dan singkatan yang lebih lengkap. Selain itu, pendekatan modeling dapat ditingkatkan dengan menerapkan metode feature selection untuk mengurangi noise dari fitur yang kurang informatif.

13. Daftar Pustaka

Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan, mengikuti format APA. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Daftar Pustaka. Pustaka yang disitasi maksimal 7 tahun terakhir sebanyak minimal 10 pustaka, dengan **referensi utama dari paper atau artikel bereputasi internasional**

- Camizuli, E., & Carranza, E. J. (2018). Exploratory Data Analysis (EDA) . In *The Encyclopedia of Archaeological Sciences* (pp. 1–7). Wiley.
<https://doi.org/10.1002/9781119188230.saseas0271>
- Chen, H., Hu, S., Hua, R., & Zhao, X. (2021). Improved naive Bayes classification algorithm for traffic risk management. *Eurasip Journal on Advances in Signal Processing*, 2021(1). <https://doi.org/10.1186/s13634-021-00742-6>
- Floranti, A. D. (2022). Racism Toward Chinese Ethnic Group in Indonesian Social Media: Hate Speeches Analysis from Forensic Linguistic Perspective. In *FISS* (Vol. 2, Issue 2).
- HaCohen-Kerner, Y., Miller, D., & Yigal, Y. (2020). The influence of preprocessing on text classification using a bag-of-words representation. *PLoS ONE*, 15(5).
<https://doi.org/10.1371/journal.pone.0232525>
- Kaur, H., Pannu, H. S., & Malhi, A. K. (2019). A systematic review on imbalanced data challenges in machine learning: Applications and solutions. In *ACM Computing Surveys* (Vol. 52, Issue 4). Association for Computing Machinery.
<https://doi.org/10.1145/3343440>
- Kurani, A., Doshi, P., Vakharia, A., & Shah, M. (2023). A Comprehensive Comparative Study of Artificial Neural Network (ANN) and Support Vector Machines (SVM) on Stock Forecasting. In *Annals of Data Science* (Vol. 10, Issue 1, pp. 183–208). Springer Science and Business Media Deutschland GmbH.
<https://doi.org/10.1007/s40745-021-00344-x>

- Liu, C.-Z., Sheng, Y.-X., Wei, Z.-Q., & Yang, Y.-Q. (2018). *Research of Text Classification Based on Improved TF-IDF Algorithm*.
- Muawanah, S., Muzayanah, U., Pandin, M. G. R., Alam, M. D. S., & Trisnaningtyas, J. P. N. (2023). Stress and Coping Strategies of Madrasah's Teachers on Applying Distance Learning During COVID-19 Pandemic in Indonesia. *Qubahan Academic Journal*, 3(4), 206–218. <https://doi.org/10.48161/Issn.2709-8206>
- Peng, J., Wu, W., Lockhart, B., Bian, S., Yan, J. N., Xu, L., Chi, Z., Rzeszotarski, J. M., & Wang, J. (2021). DataPrep.EDA: Task-Centric Exploratory Data Analysis for Statistical Modeling in Python. *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2271–2280. <https://doi.org/10.1145/3448016.3457330>
- Qaiser, S., & Ali, R. (2018). Text Mining: Use of TF-IDF to Examine the Relevance of Words to Documents. *International Journal of Computer Applications*, 181(1), 25–29. <https://doi.org/10.5120/ijca2018917395>
- Sajeetha Thavareesan, & Sinnathamby Mahesan. (2019). *2019 14th Conference on Industrial and Information Systems (ICIIS)*. IEEE.
- Sartini, N. W., & Adrian, D. (2023). Symbolic violence and discrimination in a social media comment section: A study on discriminatory discursive strategies targeting non-binary gender identity in the context of Indonesia. *Cogent Arts and Humanities*, 10(2). <https://doi.org/10.1080/23311983.2023.2270287>
- Singh, A. K., & Shashi, M. (2019). Vectorization of text documents for identifying unifiable news articles. *International Journal of Advanced Computer Science and Applications*, 10(7), 305–310. <https://doi.org/10.14569/ijacsa.2019.0100742>
- Speiser, J. L., Miller, M. E., Tooze, J., & Ip, E. (2019). A comparison of random forest variable selection methods for classification prediction modeling. In *Expert Systems with Applications* (Vol. 134, pp. 93–101). Elsevier Ltd. <https://doi.org/10.1016/j.eswa.2019.05.028>
- Surya Prabha PM, & Subbulakshmi B. (2019). *2019 International Conference on Vision Towards Emerging Trends in Communication and Networking (ViTECoN)*. IEEE.
- Wang, S., Dai, Y., Shen, J., & Xuan, J. (2021). Research on expansion and classification of imbalanced data based on SMOTE algorithm. *Scientific Reports*, 11(1). <https://doi.org/10.1038/s41598-021-03430-5>